

mon document R

Yongcheng MA

16 janvier 2022

Table des matières

1	R	2
2	opération de données	2
2.1	vectoriel	2
2.2	matrice	2
2.3	array	3
2.4	data frame	4
2.5	lire les fichier	5
2.6	écrire des fichier	5
2.7	function	6
2.7.1	la fonction de statistique	6
2.7.2	tirer des donnée	7
2.7.3	transposition	7
2.7.4	boucle for,while	7
2.7.5	la tube	8
2.7.6	apply	9
2.7.7	function édition	9
2.7.8	rnorm,runif,normalisation	10
2.7.9	table	11
2.7.10	chercher des solution pour équation	11
2.7.11	solve	11
2.7.12	authendifier deux type de valeur	12
2.7.13	cumulation de sum	12
2.7.14	unique,which,in	12
2.8	executer des fichier scripte de R	12
2.9	facteur	13
2.10	chaine caractère	13
2.11	nettoyer des données	14
2.11.1	examiner des valeur manquant	14
2.11.2	valeur manquant	14
2.11.3	explorer	14
2.12	debug	14

3	marche learning	15
3.0.1	régression linéaire	15
3.0.2	PCA	15
3.0.3	régression multiple linéaire	16
3.0.4	non-linéaire	17
3.0.5	K-means	18
4	connecter database	18
4.0.1	mysql	18
5	graph	18
6	R avec logiciel de bigdata, RHadoop,RHive,RHipe	22

1 R

2 opération de données

2.1 vectoriel

— créer un vectoriel

```

1      a <- c(1:3)
2      b <- seq(from=0,to =100,by =2)
3      d <- rep(1,4)
4
5      a <- append(a,10)
6      a <- append(a,4,after=30)
7      a <- replace(a,2,10)
8      a[-2] # supprimer un element
9      sum(a)
10     sort(a)
11     rev(sort(a)) #sum(),max(),min(),
12                 #range(),mean(),var(),sort(),
13                 #rev(),prod(),sd()
14
15     sample(x,size,replace=F)
16     rnorm(10)
17     runif(20,min=0,max =100)
18

```

2.2 matrice

— générer une vectoriel aléatoire

```

1      a <- rnorm(16)
2      class(a)
3      mode(a)
4

```

— créer une matrice

```

1 y <- matrix(5:24, nrow=4, ncol=5, byrow=TRUE)
2 x <- c(2,45,68,94)
3 rnames <- c("R1", "R2")
4 cname <- c("C1", "C2")
5 matrice <- matrix(x, nrow=2, ncol=2, byrow=TRUE,
6                   dimnames=list(rnames, cname))
7

```

— rbind cbind

```

1 x1 = c(2,4,6,8,0)
2 x2 = c(1,3,5,7,9)
3 rbind(x1,x2) # fusionner les lignes
4 cbind(x1,x2) # fusionner les colonnes
5

```

— which

```

1 a = c(2,3,4,2,5,1,6,3,2,5,8,5,7,3)
2 which.min(a)
3 which(a==2)
4 which(a>5)
5 a[which(a>5)]
6

```

— deux matrices multiplie

```

1 a = matrix(1:12, nrow=3, ncol=4) \\
2 b = matrix(1:12, nrow=4, ncol=3) \\
3 a \% * \% \\
4

```

— diag(a)

```

1 a = matrix(1:16, nrow=4, ncol=4)
2 diag(a)
3 diag(diag(a))
4 diag(4)
5

```

2.3 array

— authentifier le type

```

1 x = c(1:6)
2 is.vector(x)
3 is.array(x)
4

```

— créer une array, array() :

```

1 dim1 <- c("A1", "A2", "A3")
2 dim2 <- c("B1", "B2")
3 dim3 <- c("C1", "C2", "C3", "C4")
4 d <- array(1:24, c(3,2,4),
5           dimnames=list(dim1, dim2, dim3))
6
7 #comment prendre l'element dans la array
8 d[1,2,3]

```

```

9      d[,2]
10      sum(d[1,,])
11

```

— attach()

```

1      mtcars$mpg
2      attach(mtcars)
3      mpg
4      detach(mtcars)
5      ls() #consulter le objet dans le memoir de R
6

```

— importer des données par le clavier

```

1      mydata <- data.frame(age= numeric(0),
2                          gender=character(0),
3                          weigth=numeric(0))
4      mydata <- edit(mydata) ou fix(mydata)
5

```

2.4 data frame

— data.frame

```

1      x1 <- c(10,13,45,26,23,12,24,78,23,43,31,56)
2      x2 <- c(20,65,32,32,27,87,60,13,42,51,77,35)
3      x <- data.frame(x1,x2)
4      x <- data.frame('points' = x1 , 'prix' =x2)
5      plot(x) <- peintre la graphe
6

```

— créer un data frame :

```

1      name <-c('kg','ky','kq')
2      sex <- c('m','m','f')
3      age <- c(22,21,24)
4      mat <- data.frame(name,sex,age)
5
6      mat$score <- c(80:82) #ajouter une propriete
7      mat[which(mat$score == 82),] #consulter des lignes
8                                #qui correspondent la condition
9

```

— convertir la matrice à data frame

```

1      mat2 <- matrix(c(1:12),nrow = 3)\
2      mat3 <- as.data.frame(mat2)
3

```

merge

— union deux data frame merge() :

```

1      mat0 <- data.frame(name=name,
2                          weihl = c(60:62),
3                          age=v(20,23,24))
4      merge(mat,mat0,

```

```

5         by.x = 'age',
6         by.y = 'age')
7

```

— attacher des data frame :

```

1     rm(name)
2     attach(mat)
3     rbind(mat,mat0) #rbind() union tous les lignes,
4                     #mais les colonnes identique,
5                     cbind() union tous les colonnes,
6                     #mais les lignes identiques:
7     cbind(mat,mat0)
8     name
9

```

— lapply(),sapply()

```

1     lapply(mat0[-1,-2],sum) #calculer la somme de chaque
2                             colonne,
3                             #retourner un list
4     sapply(mat0[-1,-2],sum) #calculer la somme de chaque
5                             colonne,
6                             #retourner un vectoriel
7

```

2.5 lire les fichier

— charger fichier excel par RODBC

```

1     local({ pkg <- select.list(
2               sort(.packages(all.available = TRUE)),
3               graphics=T$ + if(nchar(pkg))
4     library(pkg, character.only=TRUE )})
5     library(RODBC)
6     z <- odbcConnectExcel('chemin de fichier de excel')
7     w <- sqlFetch(z,"Sheet1")
8

```

— lire et écrire dans le fichier

```

1     data <- read.table("chemin de fichier txt",header=TRUE,
2     sep=",") \\
3     data <- read.csv("chemin de fichier de csv ",header =
4     TRUE, sep=",") \\
5     write.csv(data,'chemin de fichier',row.names=F)\\
6     write.table(data,'chemin de fichier',sep=' ') \\
7

```

2.6 écrire des fichier

— seq()

```

1     num <- seq(10378001,10378100)
2     x1 <- round(runfi(100,min =80, max =100))
3     x2 <- round(rnom(100,mean = 80,sd =7))
4     x3 <- round(rnom(100,mean = 83,sd =18))

```

```

5     x3[which(x3 > 100)] <- 100
6     x <- data.frame(num,x1,x2,x3)
7     write.table(x,file='chemain de fichier qu'on veut
8     enregistrer',
9                 col.names=F,row.names=F,sep=' ' )

```

— sauvegarder des données dans un fichier

```

1     png('france.png')
2     map('france')
3     dev.off()

1     setwd('chemin de fichier')
2     image <- c(1,2,3)
3     for (i in c(1:10)) {
4         filename <- paste0(i,'jep')
5         jpeg(filename)
6         plot(d)
7         dev.off()
8

```

2.7 fonction

2.7.1 la fonction de statistique

— mean sum max min var prod sd

```

1     x = c(1:100)
2     sum(x)
3     max(x)
4     min(x)
5     var(x)
6     prod(x) -> factoriel\\
7     sd(x)
8     abs()
9     sqrt()
10    log2()
11    log10()
12    log(c,base=)
13    log(a,base=exp(1))
14

```

calculer en math

—

+, -, *, /

```

1     /* +, - ,* , /, %, %/,sqrt(),prod()
2     abs(),sign(),log2(),log10(),
3     log(number,base=3),
4     log(numner,base=exp(1)), ?identical */
5
6     cumsum(1:5)
7     cumprod(1:5)

```

```

8
9      a <-c(rep(1,3),
10           rep(2,3),
11           rep(6,7),
12           1:10)
13
14      a
15
16      unique(a)
17
18      sin(),
19      cos(),
20      tan()

```

2.7.2 tirer des donnée

— rev sort ,order

```

1      a = 1:20
2      rev(a)
3      a = c(2,3,4,2,5,1,6,3,2,5,8,5,7,3)
4      b <- sort(a)
5      rev(b)
6      index <- order(a,decreasing=FALSE) or order(-a)
7      a[index]
8
9      dat <- data.frame(name=c('kg','ky','kq'),score=c
10      (89,90,79))
11      dat[order(dat$score,decreasing=TRUE),]

```

2.7.3 transposition

— t() transposition

```

1      a = matrix(1:12,nrow=3,ncol=4)
2      a
3      t(a)
4

```

— eigen() chercher le caractéristique de la matrice

```

1      a <- diag(4) + 1
2      a.e <- eigen(a,symmetric=T)
3      a.e
4      a.e$vectors %*%diag(a.e$values) %*% t(a.e$vectors)
5

```

2.7.4 boucle for,while

— for

```

1      for ( i in 1:59)
2      {
3          a[i] = i * 2 + 3
4      }

```

```

5
6     a[1] = 5
7     i = 1
8     while(a[i] < 121){
9         i = i +1;
10        a[i] = a[i-1] + 2
11    }
12
13        e <- 1
14        i <- 1
15        while (1/prod(1:i) -1 / prod(1:(i+1)) > 0.001){
16            print(i)
17            e <- e+1 / prod(1:i)
18            i <- i+1
19        }
20

```

— récursif

```

1     f <- function(a=1,b=1){
2         d <- a + b
3         a <- b
4         b <- d
5         if (d>1000)
6         {
7             return(d)
8         }
9         f(a,b)
10    }
11    s <- f()
12    s
13

```

2.7.5 la tube

la fonction de tube

1 utiliser fonction de tube,pour l'équation suivante %>%

$$f(x) = \sin((x+1)^2)$$

```

1     a %>% f(b) => f(a,b)
2     a %>% f(b,.,c) => f(b,a,c)
3     f <- function(x){
4         return(x+1)
5     }
6     f2 <- function(x){
7         return(x**2)
8     }
9     f3 <- function(x){
10        return(sin(x))
11    }
12    x <- 4
13    x %>% f() %>% f2() %>% f3()
14

```

2 utilise unite


```

1 library(tidyr) #importer package
2 data <- Sys.Date()
3 date <- as.Date('2017-6-22') + 0:14
4 hour <- sample(1:24,15)
5 min <- sample(1:60,15)
6 second <- sample(1:60,15)
7 dat <- data.frame(date,hour,min,second)
8 dat %>% unite(dateHour,date,hour,sep=' ')%>%
9 unite(dateHourMinute,dateHour,min,sep=':')%>%
10 unite(DH,dateHourMinute,second,sep=':')
11 # identique que au dessus
12 dat %>% unite(dateHour,date,hour,sep=' ')%>%
13 unite(dh,dateHour,min,second,sep=':')
14

```

2.7.6 apply

apply()

— fonction apply

```

1 mean(x)
2 cloMeans(x)
3 cloMeans(x)[c('x1','x2','x3')]
4 apply(x,2,mean) # 2 represent dans le colum,
5 #1 represent dans le ligne
6 apply(x[c('x1','x2','x3')],1,sum) #- 2 represent
7 dans le colum,
8 #1 represent dans le ligne
9
10 x <- cbind(3,c(1:5,4:1))
11 apply(x,1,mean)
12 x <- array(c(1:24),dim=c(2,3,4))
13 apply(x,3,mean)

```

2.7.7 fonction édition

— la fonction simple

```

1 f <- function(x){
2   print(x)
3 }
4 f('bonjour')
5

```

— défénier une fonction

```

1 mydata <- function(type){
2   with(type,long = format(sys.time(),"%A %B %d %Y
3   "),\\
4     short = format(sys.time(),"%m-%d-%y"),\\
5     cat(type,"is not recoginzed type")
6   }
7   mydata("long")
8
9   sum <- function(num){

```

```

9       x <- 0
10      for(i in 1:num){
11        x <- x + i
12      }
13      return(x)
14    }
15

```

— calculer le produit de deux matrices

```

1  mat0 <- matrix(c(1:12),nrow = 3,byrow = T)
2  mat1 <- matrix(c(1:24),nrow = 4,byrow = T)
3  f <- function(mat0,mat1){
4    xcol = dim(mat0)[2]
5    yrow = dim(mat1)[1]
6    if (xcol != yrow){
7      print('deux matrices ne peuvent pas manipuler')
8      return(0)
9    }
10   n = dim(mat0)[1]
11   m = dim(mat1)[2]
12   mat_pro = matrix(0, nrow =n, ncol = m)
13   for (i in c(1:n) ){
14     for (j in c(1:m)) {
15       mat_pro[i,j] =sum(mat0[i,] * mat1[,j] )
16     }
17   }
18   return(mat_pro)
19 }
20 mrt <- f(mat0,mat1)
21 print(mrt)
22 mat0 % * % mat1
23

```

2.7.8 rnorm,runif,normalisation

— rnorm

```

1      n <- 100
2      a <- rnorm(n,mean=0,sd=1)
3
4      n <- 100
5      a <- rnorm(n,mean=5,sd=2) #mean(moyeen) sd(
6      variance)

```

[language= python]

— runif

```

1      n <- 100
2      a <- rnorm(n,min=0,max=1) #min(valeur minimale)
3      max(valeur maximum)

```

[language= python]

2.7.9 table

— table()

```
1 a <- c(1,4,6,8,3,4,6,6,6,8,6,1)
2 b <- table(a)
3 b == max(b)
4 names(b)
5 as.numeric(names(b)[b == max(b)])
6
```

2.7.10 chercher des solution pour équation

— calculer valeur d'équation

$$y = a * x + b$$

```
1 f <- function(x,a,b){
2   return(a*x + b)
3 }
4 root <- uniroot(f,
5   c(-10,10),
6   a=5,
7   b=10,
8   tol=0.0001) #la marge d'erreur
9 root$root
10 f <- function(x,a,b,c){
11   return a*(x**2) +b*x +c
12 }
13 uniroot(f,c(-10,10),a=5,b=10,c=6,tol=0.0001)
14
```

— chercher des valeurs d'équation

$$\begin{cases} 3x_1 + 5x_2 = 4 \\ x_1 + 2x_2 = 1 \end{cases}$$

```
1 f <- matrix(c(3,5,1,2),nrow=2,byrow=TRUE)
2 rf <- matrix(c(4,1),nrow=2)
3 solve(f,rf)
4
```

2.7.11 solve

— solve() régler un système d'équation

```
1 a <- matrix(rnorm(16),4,4)
2 b <- c(1:4)
3 solve(a,b)
4
```

2.7.12 authentifier deux type de valeur

— identical

```
1 identical(1, NULL)
2 identical(1, is.integer())
3 is.integer(1)
4 identical('1', is.character('1'))
5
```

[language= python]

2.7.13 cumulation de sum

— cumsum(), cumprod()

```
1 cumsum(1:15)
2 cumprod(1:15)
3
```

[language= python]

2.7.14 unique, which, in

— unique()

```
1 a <- c(rep(1,3), rep(2,3), rep(4,7), 1:10)
2 b <- unique(a)
3
```

[language= python]

— which()

```
1 a <- c(rep(1,3), rep(2,3), rep(4,7), 1:10)
2 c <- a[which(d>5)]
3
4 a <-c(1:10)
5 b <-c(1:10)
6 dat <- data.frame(a,b)
7 dat[which(dat[,1] > 5),]
8 dat[which(dat[,1] > 5),1]
9
```

[language= python]

— %in%

```
1 x %in% y # verifier x dans le y
2
```

[language= python]

2.8 executer des fichier scripte de R

— source()

```
1 path <- 'repertoire de fichier'
2 setwd(path)
3 getwd()
```

```

4 list.files()
5 source('nom de scripte de R')
6 source("chemain de scripte de R")
7

```

2.9 facteur

— créer un facteur

```

1 a <- factor(c('A','B','C','A','B'))
2 a <- factor(c('A','B','C','A','B'),
3           levels =c('A','B'))
4 a <- factor(c('A','B','C','A','B'),
5           levels =c('A','B','C'),
6           labels= c('Tres Bien','Bine','Mauvais'))
7
8 a <- factor(c('A','B','C','A','B'),
9           exclude = 'A'))
10
11 score <- c('A','B','A','C','B')
12 score1 <- ordered(score,
13                 levels=c('C','B','A'))
14
15 dataset <- c(...)
16 examen <- cut(dataset,breaks=3)
17

```

— tapply()

```

1 gender <- c('f','m','m','m','f')
2 age <- c(12,35,25,12,25)
3 tapply(age,gender,mean)
4

```

2.10 chaine caractère

— strsplit()

```

1 s <- '123,234,56'
2 strsplit(s,',')
3 unlist(strsplit(s','))
4
5 s <- 'a b c'
6 s1 <- 'w x v'
7 paste(s,s1,sep=',')
8 paste0(s,s1) #paste() paste0()
9

```

— nchar(),length()

```

1 s <- 'a b c'
2 nchar(s)
3 length(s)
4

```

— substr() substring()

```

1 s <- 'a b c'
2 substr(s,2,3)
3 substring(s,2)
4

```

2.11 nettoyer des données

2.11.1 examiner des valeur manquant

— examiner des valeur manquant `complete.cases()` :

```

1 a <- matrix(c(1:6,NA,8,9),nrow=3)
2 complete.cases(a);
3 a[complete.cases(a)]
4 a[complete.cases(a),]
5 b <- c(1,2,NA)
6 complete.cases(a,b);
7 na.omit(a)
8

```

2.11.2 valeur manquant

— remplie des valeur manquant

```

1 x <- c(1,NA,2,NA,3)
2 x[!is.na(x)]
3 y <- c('a','b',NA,'c',NA)
4 z <- complete.cases(x,y);
5 x[z]
6 y[z]
7 g <- complete.cases(airquality)
8 airquality[g,]
9

```

2.11.3 explorer

— explorer des données

```

1 mat <- iris[1:4]
2 mean(mat[,1])
3 median(mat[,1])
4 quantile(mat[,1])
5 range(mat[,1]) #afficher le valeur maximum et minimum
6 var(mat)
7 sd(mat[,1])
8 summary(mat)
9

```

2.12 debug

— test code

```

1      cou <- function(count)
2      {
3          s <- 0
4          i <- 1
5          while(i < count +1)
6          {
7              s <- s + i
8              i <- i + 1
9              browser()
10             }
11             return(s)
12         }
13     debug(cou)
14     cou(10)
15     appuyer n #next
16     appuyer i # afficher la valeur de variable
17     print(s) #afficher la valeur de variable
18     q # quitter debug
19     browser() # appuyer c pour debug le boucle
20
21

```

3 marche learning

3.0.1 régression linéaire

— calculer le paramètre de régression de linéaire

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}, \beta_0 = \bar{y} - \beta_1 * \bar{x} \quad (1)$$

— régression linéaire

```

1      y <-matrix(5:24,nrow=4,ncol=5,byrow=TRUE)
2      x <- c(2,45,68,94)
3      rnames <- c("R1","R2")
4      cname <- c("C1","C2")
5      matrice <- matrix(x,nrow=2,ncol=2,byrow=TURE,dimnames
6      =list(rnames,cnames))
7      res <- lm(para1 ~ para2, data)

```

3.0.2 PCA

— scale

```

1      sl <- scale(iris[,1])
2      pw <- scale(iris[,4])
3      model <- lm(pw~sl)
4      summary(model)
5      model <- lm(pw~sl-1) #-1 (supprimer la valeur
      constante)

```

```

6      plot(pw,s1,col='green')
7
8      sc <- scale(swiss)
9      pri <- princomp(sc,cor=TRUE)
10     summary(pri)
11
12     screeplot(pri,type='line')
13     pre <- predict(pri)
14     summary(pre)
15     y <- eigen(cor(sc))
16     y$values
17     scores <- (y$values[1] * pre[,1] + y$values[2] *
pre[,2] +
18             y$values[3] * pre[,3] + y$values[4] * pre[,4]
19     ) / sum(y$values)
20     plot(scores)

```

3.0.3 régression multiple linéaire

— régression multiple linéaire

$$y = \beta_0 + \beta_1 * x_1 + \beta_2 * x_2 + \dots + \beta_k * x_k + \epsilon$$

pour quelque soit

$$x_i$$

on a

$$x_i = (x_{1i}, x_{2i}, x_{3i}, \dots, x_{ki}), x_1 = (x_{11}, x_{21}, x_{31}, \dots, x_{k1})$$

marge d'erreur

$$\epsilon_i = y_i - (\beta_0 + \beta_1 * x_{i1} + \beta_2 * x_{i2} + \dots + \beta_k * x_{ik})$$

```

1      rm(list=ls()) # vider la variable de la memoire
2      s.l <- scale(iris[,1])
3      s.w <- scale(iris[,2])
4      p.l <- scale(iris[,3])
5      p.w <- scale(iris[,4])
6
7      model <- lm(s.l,~s.w + p.l + p.w)
8
9      plot(model,1,col='red') # 1.merge d'erreur
10     plot(model,2,col='red') # 2 qq graphe
11     s.l <- 0.34*s.w + 1.511p.l - 0.512 *p.w
12
13
14     blood <- data.frame(
15         x1 = c(76.0,91.5,85.5,82.5,79.0,80.5,
16               74.5,79.0,85.0,76.5,82.0,95.0,92.5)
17         x2 = c(50,20,20,30,30,50,60,50,40,55,40,20)
18         y = c(120,141,124,126,112,125,
19               123,125,132,123,132,155,147))
20     lm.sol <- lm(y~x1+x2,data=blood)
21     summary(lm.sol)

```



```

22     s <- lm(y ~ ., data = blood)
23     summary(s)
24     toothpaste <- data.frame(
25         x1=c(-0.05,0.25,0.06,0,0.25,0.20,0.15,
26
27         0.05,-0.15,0.15,0.20,0.10,0.40,0.45,0.35,
28
29         0.30,0.50,0.50,0.40,-0.05,-0.05,-0.01,
30         0.20,0.10,0.50,0.60,-0.05,0,0.05,0.55)
31         x2 = c(5.50,6.75,5.00,4.98,7.25,5.50,7.00,
32         6.50,6.75,25.5,25.6,6.00,6.50,6.25,
33         7.00,6.90,6.80,7.10,7.00,6.80,6.50,
34
35         6.25,6.00,6.50,7.00,6.80,6.50,5.75,5.80,6.80)
36         y = c
37         (7.38,8.51,9.52,7.50,9.33,8.28,8.75,
38
39         7.87,7.10,8.00,7.89,8.15,9.10,8.86,8.90,
40
41         8.87,9.26,9.00,8.75,7.95,7.65,7.27,8.00,
42
43         8.50,8.75,9.21,8.27,7.67,7.93,9.26)
44     )
45     lm.sol <-lm(y~x1+x2,data = toothpaste)
46     summary(lm.sol)
47     lm.new <-update(lm.sol,~.+I(x2**2)) #mettre a jour
48     notre modele
49     summary(lm.new)
50     lm2.new <-update(lm.new,~-x2) #supprimer facteur x2
51     summary(lm2.new)
52     lm3.new <-update(lm2.new,~.+x1 * x2) #ajouter un
53     facteur x1 * x2
54     summary(lm3.new)
55     lm.step <- step(lm3.new)
56     drop(lm.step)

```

3.0.4 non-linéaire

— la modèle non-linéaire

```

1     x <- c
2     (1.5,2.8,4.5,7.5,10.5,13.5,15.1,16.5,19.5,22.5,24.5,26.5)
3     y <- c
4     (7.0,5.5,4.6,3.6,2.9,2.7,2.5,2.4,2.2,2.1,1.9,1.8)
5     lm.log <- lm(y~ log(x))
6     summary(lm.log)
7     lines(x,exp(fitted(lm.log)))
8     lm.exp <- lm(log(y) ~ x)
9     summary(lm.exp)
10    lines(x,exp(fitted(lm.exp)))
11    lm.pow <- lm(log(y) ~ log(x))
12    summary(lm.pow)
13    lines(x,exp(fitted(lm.pow)))

```

3.0.5 K-means

— k-means

```
1      c1 <- (14,22,15,20,30,18,32,13,
2            23,20,21,22,23,24,35,18)
3      c1 <- (15,28,18,30,35,20,30,15,
4            25,23,24,25,26,27,30,16)
5      kc <- kmeans(dat,3)
6      summary(kc)
7      kc$centers
8      kc$cluster
9      qplot(dat[1,],dat[,2],colour=kc$cluster)
10
```

4 connecter database

4.0.1 mysql

11 R connecter base de donnée mysql,

```
1      /**1. install.packages("RODBC"). */
2
3      library(RODBC)
4      myconne <- odbcConnect("nom de data base",uid="
5      root",pwd="password")
6      data1 <- sqlFetch(myconn,"nom de table")
7
8      data2 <- sqlQuery(myconn,"select * from nom de
9      table")
10      close(myconn)
```

— examiner la modèle est normalisation

```
1      shapiro.test(x$x1)
2      shapiro.test(x$x3)
3      y.res <- residuals(lm.sol)
4      norell <- data.frame(x=0:5,
5      n = rep(70,6),
6      success = c(0,9,21,47,60,63)
7      norell$Ymat<-cbind(norell$success,
8      norell$n-norell$success)
9
10     glm.sol <- glm(Ymat~x,family = binomial,
11     data = norell)
12     summary(glm.sol)
13
```

5 graph

— barplot

```
1      colors()# lister toutes les couleurs dans le R
```

```

2 palette()#lister toutes les couleurs dans la palette d'
  actuelle
3 barplot(c(88,78,100),
4         names.arg=c('eric','alen','fabien'),
5         ylim=c(0:100),
6         col=rainbow(3),
7         legend.text = c('eric','alen','fabien'))
8
9 hist(iris[,1],freq=T)
10 hist(iris[,1],freq=F)
11 pie(c(1,2,3),lables=c('chine','france','etat-unis'),
12     radius=0.5)
13 boxplot(iris[,c(1:4)],
14         notch=T,
15         col=rainbow(4),
16         names=c('sl','sw','pl','l'))
17

```

— qplot()

```

1 dat <- diamonds[sample(nrow(diamonds),200),]
2 names(dat)
3 qplot(dat$carat,dat$price)
4 unique(dat$color)
5 qplot(carat,price,data=dat,colour=color)
6 qplot(carat,price,
7       data=dat,colour=color,
8       shape=mat$cut)
9
10 qplot(carat,price,
11       data=dat,colour=color,
12       shape=mat$cut,alpha=I(1/10))
13

```

— comment peindre un image

```

1 apply(x[c('x1','x2','x3')],1,sum) # 2 represent dans
  le colum,
2
3 #1 represent dans le ligne
4
5 whitch.max(x[c('x1','x2','x3')],1,sum) #chercher plus
  grand de note
6
7 x$num[whitch.max(x[c('x1','x2','x3')],
8                 1,sum)] #chercher le numero d'etudiant
  # qui est plus grand de note
9
10 hist(x$x1)
11 plot(x1,x2)
12 plot(x$x1,x$x2)
13 pie(table(x$x1)) # circle
14 boxplot(x$x1,x$x2,x$x3) \
15 boxplot(x$x1,x$x2,x$x3,horizontal = T)
16 boxplot(x[2:4],
17         col=c('red','green','blue'),
18         notch = T)
19 stars(x[c('x1','x2','x3')])
20 stars(x[c('x1','x2','x3')],
21       full = T,draw.segment = T)

```

```

22     stars(x[c('x1','x2','x3')],
23           full = F,draw.segment = T)
24
25     faces(x[c('x1','x2','x3')]) #image de face install
package aplpack
26
27     faces2(x) #autre face de image,
28     #install package TeachingDemo
29     stem(x$x1) #image de tige et feuille
30     qqnorm(x1)
31     qqline(x1)
32     qqnorm(x3)
33     qqline(x3)
34     plot(x$x1,x$x2,
35          main='titre de image',
36          xlab='x de lable',
37          ylab='y de label',
38          xlim = c(0,100),
39          ylim=c(0,100),
40          xaxs='i', le sytel de x
41          yaxs='i', le sytel de y
42          col = 'red',\\
43          pch = 19 le sytel de point de image)
44

```

```

1     a = c(2,3,4,5,6)
2     b = c(4,7,8,9,12)
3     plot(a,b,type='l') utile un fil lie les points
4     plot(rain$Tokyo,type='l',col='red',
5          ylim=c(0,300),
6          main = 'le pleut de mois dans la ville',
7          xlab = 'mois d'annee',
8          ylab = 'quantite de pleut(mm)',
9          lwd = 2 ) la large du fil
10
11     lines(rain$NewYork,type='l',col='blue',lwd=2)
12     lines(rain$London,type='l',col='green',lwd=2)
13     lines(rain$Berlin,type='l',col='orange',lwd=2)
14

```

— density()

```

1     plot(density(rnorm(1000)))
2

```

— consulter la dataset in system de Rstudio *data()* on peut trouver mtcars

— heatmap

```

1     heatmap(as.matrix(mtcars),Rowv =NA,
2             Colv =NA, col = heat.colors(256),
3             scale = 'column',margins = c(2,8),
4             main = 'Car caracteristique de model')
5

```

— par

```

1     par(mfrow = c(3,1)) #mettre 3 lignes 1 colonne
2         #pour mettre les trois graphes
3     plot(x1,x2)

```

```

4      plot(x2,x3)
5      plot(x3,x1)
6      install.packages(sctterplot3d)
7
8      sctterplot3d(x[2:4])
9      x <- y <- seq(-2*pi, 2*pi, pi/15)
10
11     f <- function(x,y) sin(x)*sin(y)
12     z <- outer(x,y,f)
13
14     contour(x,y,z,col='red')
15     persp(x,y,z,theta=30,phi=30,expand=0.7,col='lightblue',)
16
17     source('chemin de scripte de R')
18     unison(x[2:4])
19     install.packages(c('maps', 'geosphere'))
20     map('state',interior=FALSE)
21     map('state',boundary = FALSE,col='red',add=TRUE)
22     map('world',fill=TRUE,col=heat.colors(10))
23     map('state')
24     map('world')
25

```

— la mode de probabilité

```

1      rnorm(n,mean=0,sd=1)
2      rexp(n,rate=1)
3      rgamma(n,shape,scale=1)
4      rpois(n,lambda)
5      rweibull(n,shape,scale=1)
6      recauchy(n,location=0,scale=1)
7      rbeta(n,shape1,shape2)
8      rt(n,df)
9      rf(n,df1,df2)
10     rchisq(n,df)
11     rbinom(n,size,prob)
12     rgeom(n,prob)
13     rhyper(nn,m,n,k)
14     rlogis(n,location=0,scale=1)
15     rlnorm(n,meanlog=0,sdlog=1)
16     rnbinom(n,size,prob)
17     runif(n,min=0,max=1)
18     rwilcox(nn,m,n)
19     rsignrank(nn,n)
20

```

```

1      plot(iris[1,2])
2      i1 = iris[which(iris$Species=='setosa'),1:2]
3      plot(i1)
4      cor(i1[,1],i1[,2]) #consulter la coefficient de
correlation
5

```

```

—      h <- c
      (171,175,159,155,152,158,154,164,168,166,159,164)
2      w <- c(57,64,41,38,35,44,41,51,57,49,47,46)
3      plot(w~h+1)

```

```

4      lxy <- function(x,y){
5          n = length(x);
6          sum(x*y) - sum(x)*sum(y) /n;
7      }
8      b <- lxy(h,w)/lxy(h,h)
9      a <- mean(w) - b*mean(h)
10     lines(h,a+b*h)
11     a <- lm(w~1+h)
12     z <- data.frame(x=185)
13     predict(a,z)
14     predict(a,z,interval='prediction',level=0.95)
15

```

6 R avec logiciel de bigdata, RHadoop,RHive,RHipe